

〈Gemma (Google Open Model 계열)〉

1. 기본 정보

- 모델명 / 브랜드명: Gemma (Google DeepMind)
- 개발사 / 제공사: Google / DeepMind
- 출시 / 진화 개요:
 - 최초 Gemma 발표 (2024년 초)
 - 이후 Gemma 2, Gemma 3 발표됨
 - 최신 버전: Gemma 3 계열 (및 Gemma 3n 등 파생)
- 모델 포지셔닝 / 역할:
 - 가볍고 효율적인 오픈 모델 계열로, Gemini 기술 기반
 - 텍스트 생성, 요약, 질문 응답, 이미지 + 텍스트 멀티모달 처리 기능 포함
 - 다양한 파라미터 크기 및 양자화(quantization) 지원



2. 모델 구조 / 특징

- 멀티모달 + 대형 컨텍스트 창 지원
 - Gemma 3 (4B, 12B, 27B) 모델들은 128K 토 큰 컨텍스트 지원함
 - 이미지 입력을 텍스트로 해석하는 기능 포함
 - 소형 모델 (예: 270M, 1B) 버전도 존재하며, 텍스트 전용 기능 중심
- 양자화 / 경량화 지원
 - Gemma 3 모델들은 다양한 정밀도 (32비트, 양자화 된 버전 등)로 제공됨
- 다언어 지원
 - 140개 이상 언어 지원 가능성 명시됨
- 효율성 / 비용 측면 최적화
 - Google Cloud 상에서 Gemma는 JetStream 인프라를 통해 TPU 상에서 추론 효율성이 기존 스택 대비 최대 3배 향상된 것으로 보고됨
 - 학습 / 추론 비용 대비 성능 최적화에 중점

3. 강점 & 약점

강점	약점/제한점
Gemini 기술 기반 + 오픈 모델 계열로 접근성 높음	SWE-Bench 수치 등 일부 벤치마크 항목 미공개
멀티모달 + 대맥락 입력 가능	큰 모델은 리소스 요구량 큼
다양한 정밀도 / 양자화 옵션 존재	정밀도 / 기능 간 품질 변화 가능성
클라우드 인프라 최적화 (JetStream 등)	오픈 모델 특성상 안전/편향 제어 필요성 높음
다국어 / 멀티모달 지원	일부 기능 (예: SWE-Bench 해결률) 공개되지 않음

4. 알려진 벤치마크 / 성능 수치 (텍스트 중심)

- Gemma 모델은 “18개의 텍스트 기반 작업 중 11개에서 동일 규모 오픈 모델 대비 우수한 성능”을 기록했다는 보고 있음
- Gemma 3 벤치마크:
 - MMLU-Pro: 67.5% ([c3.unu.edu][8])
 - GPQA-Diamond: 42.4%
 - MATH: 89 점 (MATH-500 기준)
- Google Cloud 분석: JetStream 기반 추론 효율성 최대 3배 향상 보고됨

(수정일자: 2025/10/4)