

〈LLaMA〉

1. 기본 정보

항목	내용
모델명 / 브랜드명	LLaMA (Large Language Model from Meta)
개발사 / 제공사	Meta AI / Meta (Facebook 등 모회사)
출시 / 버전 진화	여러 버전 출시됨: LLaMA-1, LLaMA-2, LLaMA-3, LLaMA-3.1, LLaMA-3.2, 최근에는 LLaMA-4 Scout / Maverick 등 멀티모달 버전 공개됨
주요 용도 / 포지셔닝	공개(open-source) 또는 반-공개 foundation model로서, 연구자/기업 개발자들이 fine-tune / API / 사용 가능한 다양한 크기(파라미터 규모) 모델들을 제공함. 텍스트 생성, 코드 생성, 질의응답, 보조 어플리케이션 개발 등에 쓰임. 멀티모달(텍스트+이미지) 처리 기능도 최근 버전에서 강화됨



2. 주요 특징 (버전별 / 공통)

특징	설명
파라미터 규모 다양성	여러 크기의 모델 존재 (예: 8B, 70B, 405B 등)으로, 자원/목적에 따라 선택 가능
확장된 문맥 창(Context Length)	LLaMA 3.1 / 3.2 버전은 128K 토큰 문맥 길이 지원. 긴 문서 / 대화 / 코드베이스도 문맥 손실 적음
멀티모달 기능	특히 LLaMA-3.2 버전부터 텍스트 + 이미지 입력 (vision) 모델 있음. (예: 11B, 90B 파라미터의 vision LLMs)
언어 지원/다국어	영어 외 여러 언어(예: 독일어, 프랑스어, 스페인어, 힌디어, 타이 등) 지원. 버전마다 증가 추세
효율성 개선/도구 통합성	예: GQA (Grouped Query Attention) 등의 attention 최적화 기술, 양자화(quantization) 지원, tool-calling (검색, 수학 등 외부 도구) 통합 가능성 등이 포함됨
안전/거버넌스 기능	“Llama Guard” 등 입력-출력 안전장치, content safety 기능들이 추가됨

3. 강점 & 약점

강점	약점/고려사항
오픈소스 또는 공개 접근성이 강함 — 개발자 / 연구자 커뮤니티에 유리	일부 고급 기능 / 멀티모달 구성은 리소스 요구량이 매우 높음
크기 옵션 다양 > 경량 모델부터 대형 모델까지 목적에 맞는 선택 가능함	대형 버전들(예: 405B)은 학습/추론 비용 / 하드웨어 요구가 큼
문맥 창 길고 멀티모달 지원 확대됨 → 복합 문서 처리, 이미지/텍스트 혼합 과제에 유리	훈련 데이터 / fine-tuning 데이터가 특정 분야/언어에 치우칠 가능성 있음
언어 및 코드 생성 등 여러 과제에서 경쟁력 있음	여전히 폐쇄 모델(예: OpenAI) 대비 일부 벤치마크에서 미흡한 경우 있음
거버넌스 / 안전 기능 강화됨	규제 / 데이터 프라이버시 / 공개 정책이 지역마다 다르므로 배포/활용 시 주의 필요함

4. SWE-Bench / 벤치마크 수치

공개된 SWE-Bench 관련 LLaMA 수치들은 아래와 같다.

모델/조건	SWE-Bench 분할 (Lite / Verified / Full 등)	해결률 / 성능 수치
LLaMA 3.1	SWE-Bench 리더보드 상에 등록됨 (Lite, Verified 등)	정확 수치는 리더보드 보기에서 확인 가능하지만, 예로 SWE-Bench Lite에서 보이는 경쟁 모델군 중 하나임. (예: “Llama 3.1” 이름으로 표기됨)
SWE-Llama 13B / SWE-Llama 7B	SWE-Bench Lite / Verified / Multimodal 항목에 등장함	실제 %는 리더보드에서 확인 필요함.

5. 알려진 수치 / 예제 벤치마크 비교

- LLaMA-3.1 (405B) 모델은 여러 공개 출처에서 MMLU 등의 과제에서 상위 그룹 성능 보였다는 평 있음
- Vision 기능 포함된 LLaMA-3.2 (11B, 90B) 모델은 이미지 + 텍스트 혼합 작업에서 이전 모델 대비 큰 개선 있음
- SWE-Bench 리더보드에서 Llama 3.1/Llama variants가 여러 범주(Lite / Verified / Multimodal)에서 경쟁자 모델들과 함께 상위권에 있음

(수정일자: 2025/10/6)