

〈Qwen〉

1. 기본 정보

- 모델 / 브랜드명: Qwen (通义千问, Tongyi Qianwen)
- 개발사 / 제공사: Alibaba Cloud (Alibaba 그룹)
- 출시 및 진화 개요
 - 2023년 4월 베타 시작, 이후 정식 공개됨
 - 2024년 Qwen2 출시, 2025년 Qwen3 출시됨
 - Qwen 계열은 오픈소스/오픈웨이트 모델을 일부 공개하면서도 상업용 모델도 유지 중임
- 서비스 / 기능 포지셔닝
 - 자연어 처리, 코드 생성, 수리 추론, 멀티모달 입력 (이미지/비디오) 등 다양한 기능 지원
 - Qwen Chat 플랫폼 통해 챗 기능 + 이미지 생성 기능 함께 제공됨



Qwen

2. 버전 및 모델 계열 요약

버전/모델 계열	특징/목적	공개 여부/비고
Qwen (원 모델 계열, 초기)	기본 언어 모델 기능	초기 일부 모델 (1.8B, 7B, 14B, 72B 등) 오픈웨이트 공개됨
Qwen2 / Qwen2-VL	비전-언어 통합 기능 강화	Qwen2-VL 논문 공개됨, 문서/이미지/비디오 해석 기능 포함됨
Qwen2.5 계열	개선된 성능, 멀티모달 및 코딩 특화 모델 포함	Qwen2.5-VL, Qwen2.5-Max 등 모델 존재
Qwen3 계열	최신 모델, MoE 구조 및 고 성능 지향	Qwen3-235B-A22B 등 MoE 모델 공개됨
Qwen3-Omni	텍스트 · 이미지 · 오디오 · 비디오 통합 멀티모달 모델	Qwen3-Omni 발표됨, 다양한 입력/출력 모드 지원됨

3. 주요 특징 & 기능

- 멀티모달 입력 / 출력 지원

- Qwen 모델 계열은 단순 텍스트 입력만이 아니라 이미지/비디오/오디오 입력을 처리하거나 멀티모달 결과물을 생성 가능하도록 확장됨. 특히 Qwen2-VL, Qwen3, Qwen3-Omni 계열이 이 기능 강화됨

- 대규모 문맥 창 (Context window)

- Qwen3 계열은 128K 토큰 컨텍스트 지원함

- MoE (Mixture-of-Experts) 구조

- Qwen3-235B-A22B 같은 MoE 모델은 235B 전체 파라미터 중 22B 활성화되는 구조로 설계됨.

- 고성능 벤치마크 지향 설계

- Qwen3-Thinking-2507 모델은 LiveCode Bench v6에서 74.1 기록하며 경쟁 모델을 앞섬

- Qwen3-Thinking-2507은 AIME25 수학/논리 시험에서 92.3 점퍼기록 있음
- 속도 / 스피드 벤치마크
 - Qwen2 계열 문서에는 bf16 / quantized (Int4, Int8, AWQ 등) 모델들의 토큰 생성 속도 수치 보고됨
 - Qwen3 계열 문서에도 속도 벤치마크 보고됨 (quantized 버전 포함)

4. 강점 & 약점

4.1 강점

4.1.1 높은 벤치마크 성능

- Qwen3-235B-A22B는 여러 벤치마크에서 상위권 성능을 보임 (LiveCodeBench, MMLU 등)

4.1.2 멀티모달 통합 기능

- 이미지/비디오/오디오 기능 통합 가능 > 다양한 입력/출력 모드 지원

4.1.3 오픈 소스 / 공개 웨이트 전략

- 일부 모델은 오픈 라이선스 하에 공개됨 > 연구자/개발자 접근성 증가

4.1.4 대규모 문맥 처리 능력

- 128K 토큰 지원으로 장문 문서, 컨텍스트 유지 가능

4.2 약점 / 한계

4.2.1 공식 벤치마크 자료 제한

- 모든 버전에 대한 정량적 벤치마크 공개는 제한적임 >
일부 성능은 추정 또는 보도 기반

4.2.2 복잡성 / 비용

- MoE 모델 구조, 대규모 파라미터 처리는 실행 비용과 리소스 요구가 큼

4.2.3 버전 간 일관성 이슈

- 버전 전환 또는 설정에 따라 성능 변화 클 수 있음

4.2.4 언어 / 문화 중심 편향 가능성

- 주로 중국어/영어 중심 데이터로 학습된 부분 있을 가능성

5. 알려진 벤치마크 / 수치 예시

벤치마크/시험	모델	수치/결과	비고/출처
LiveCodeBench v6	Qwen3-Thinkin g-2507	74.1	초기 일부 모델 (1.8B, 7B, 14B, 72B 등) 오픈웨이트 공개됨
AIME25 (수리/논 리 시험)	Qwen3-Thinkin g-2507	92.3	Qwen2-VL 논문 공개됨, 문서/이미지/ 비디오 해석 기능 포 함됨
MMLU-Pro (일반 /추론 지식)	Qwen3-235B-A 22B	80.6 %	Qwen2.5-VL, Qwen2.5-Max 등 모델 존재
Qwen3-32B-Ba se	MMLU-	65.54	Qwen3-235B-A 22B 등 MoE 모델 공개됨
Qwen2 series (속도 / quantized 버전)	토큰 생성 속도 (bf16 / Int4 / Int8 / AWQ)	상세수치	Qwen3-Omni 발 표됨, 다양한 입력/출 력 모드 지원됨
SWE-Bench	Qwen3-Coder 480B / A35B Instruct	55.4%	SWE-bench 리더 보드 (SWEbench 공식)

(수정일자: 2025/10/4)